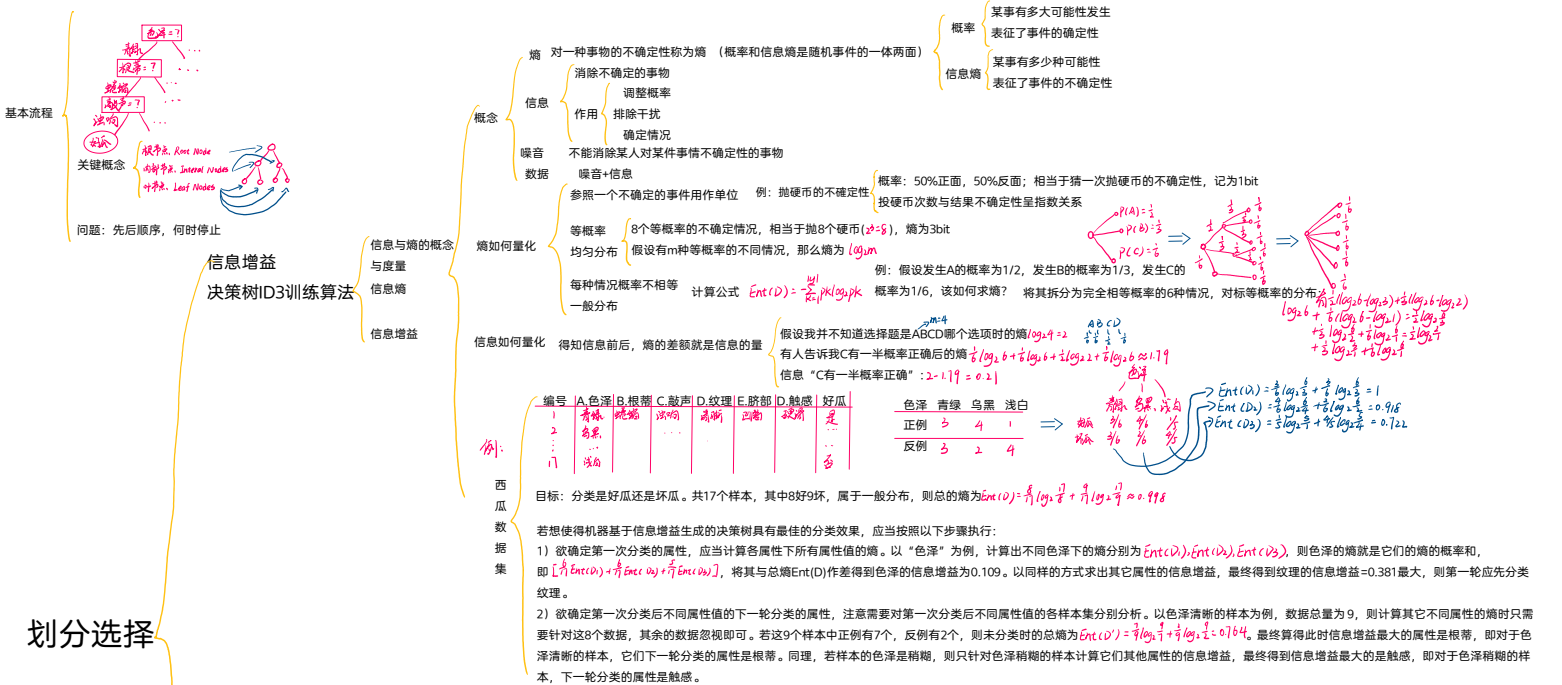
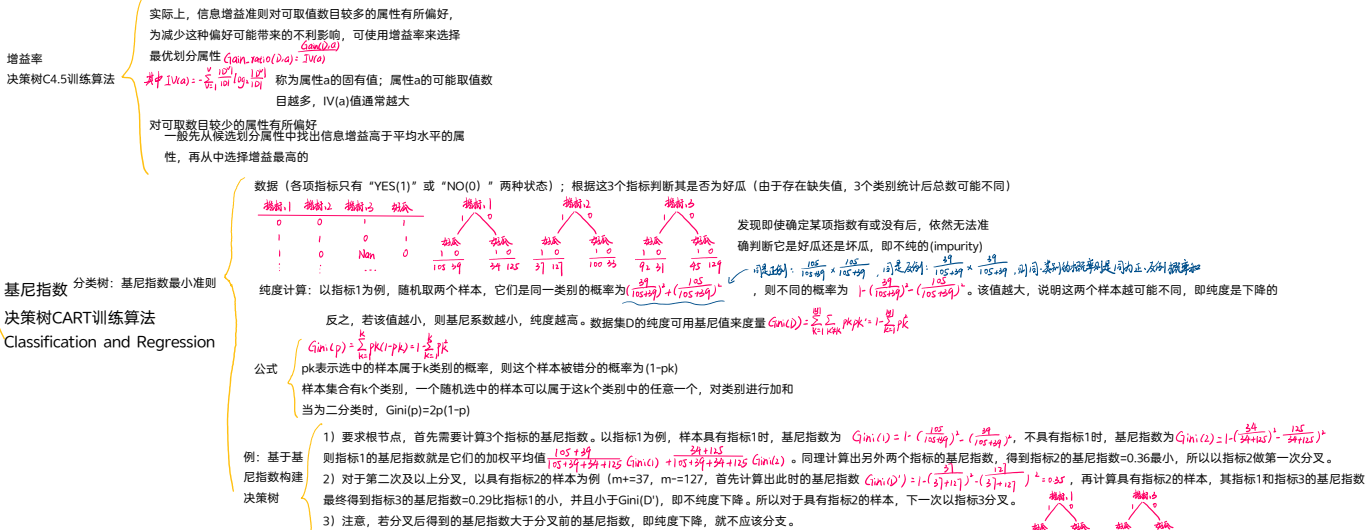


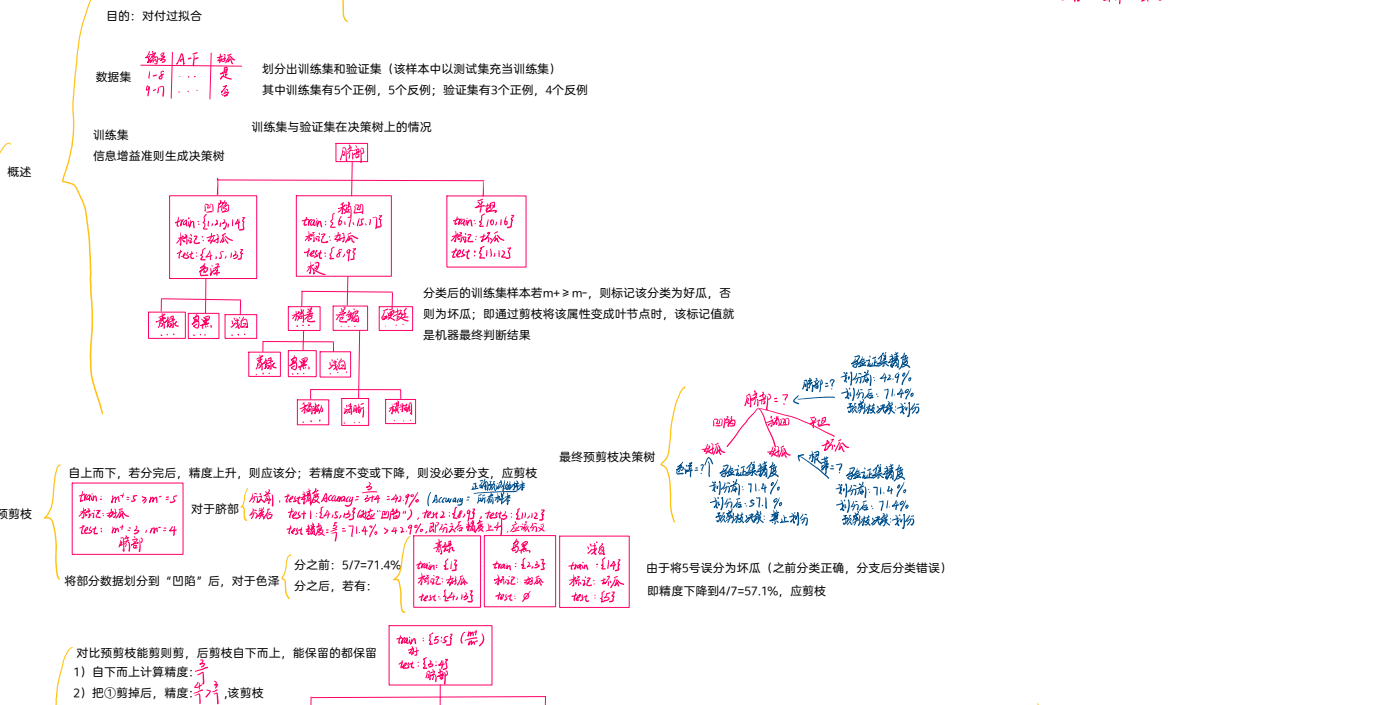
决策树



划分选择

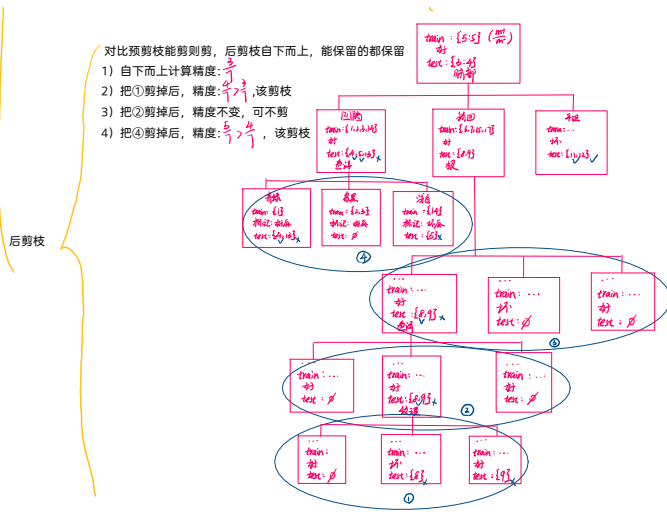


剪枝处理



连续与缺失值

多变量决策树



连续值处理 二分法，使得信息增益最大的阈值均为连续值

缺失值处理

对于集合D，按照不同的属性进行分类，这些属性的属性值均为连续值

例：根据糖浓度对西瓜数据集0例

1) 按照数据集从小到大顺序给数据样本排序

2) 通过计算信息增益，查找每一次分类的最佳阈值。

继续以剪枝处理的西瓜数据集0为例，即数据集为

其中，1-8是正例，9-17是反例。

1) 以色泽属性为例，缺失了1号，5号，13号在色泽上的数据，即无缺失值的样例子集D'中只有14个样例，计算分类前的信息熵 $Ent(D') = -\frac{14}{14} \log_2 \frac{14}{14} = 0.918$

2) 令 $\theta^1, \theta^2, \theta^3$ 分别表示在色泽属性上取值为青绿，乌黑和洁白的样本子集，有 $Ent(\theta^1) = -\frac{8}{14} \log_2 \frac{8}{14} - \frac{6}{14} \log_2 \frac{6}{14} = 0.918$ ， $Ent(\theta^2) = -\frac{1}{14} \log_2 \frac{1}{14} - \frac{13}{14} \log_2 \frac{13}{14} = 0.918$ ， $Ent(\theta^3) = -\frac{1}{14} \log_2 \frac{1}{14} - \frac{13}{14} \log_2 \frac{13}{14} = 0.918$

3) 因此，样本子集D'上色泽的信息增益为 $Gain(D, color) = Ent(D') - \frac{1}{14} Ent(\theta^1) - \frac{1}{14} Ent(\theta^2) - \frac{1}{14} Ent(\theta^3) = 0.918 - \frac{1}{14} \times 0.918 = 0.918$

4) 于是，样本集D上色泽属性的信息增益为 $Gain(D, color) = \frac{1}{14} \times 0.918 = 0.065$ ，类似地可计算出其它属性在D上的信息增益

对于正常基于连续值生成的决策树，它们不同的属性最后往往呈线性的关系，因为每次的取值都是一次二分类

多变量决策树

多变量决策树的分界点不再是对某个属性，而是对属性的线性组合进行一种测试

