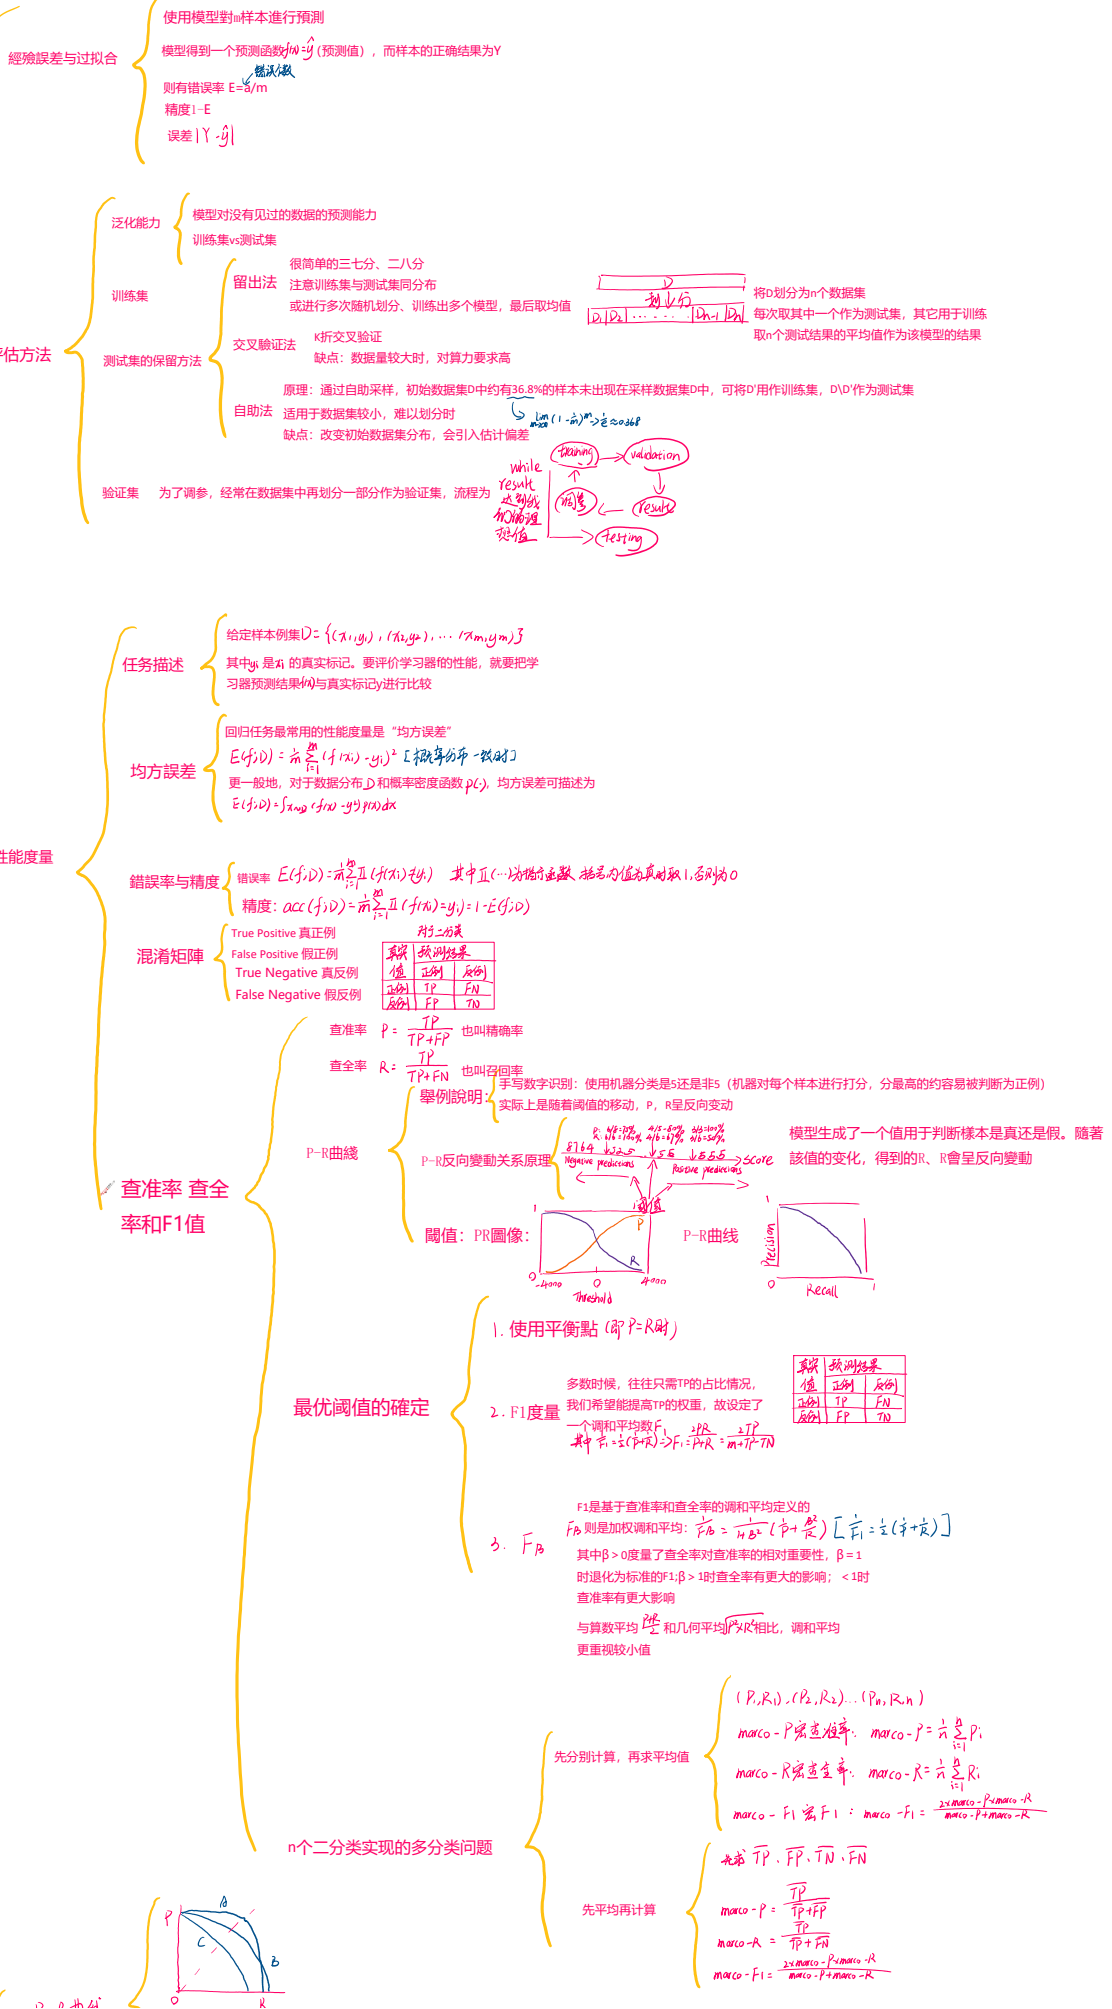


## 一種訓練集一種算法



一种训练多种算法

**P-R曲线**

PR曲线与平衡点示意图

比较ABC 3个模型的好坏

首先可以确定B和A优于C, BA之间有交叉, 无法确定

对比AB

方法1: 比较AB的面积大小, 在一定程度上表征了模型的优劣, 但是这个值不容易估算

方法2:  $F_1$

方法3:  $F_\beta$

**ROC与AUC**

ROC:

True Positive Rate:  $TPR = \frac{TP}{TP+FN}$

False Positive Rate:  $FPR = \frac{FP}{TN+FP}$

示意图

基于有限样例绘制

AUC: Area Under ROC Curve 即ROC曲线下的面积

$AUC = \frac{1}{2} \sum_{i=1}^m (x_{i+1} - x_i)(y_{i+1} - y_i)$

形式化地看, AUC考虑的是样本预测的排序质量, 因此它与排序误差有紧密联系. 给定  $m$  个正例和  $m$  个反例, 令  $1 \sim D$  表示正例集合, 则排序损失定义为  $(rank = \frac{1}{m+n} \sum_{i \in D} \sum_{j \in \bar{D}} (I(f(x_i) > f(x_j)) + \frac{1}{2} I(f(x_i) = f(x_j)))$

排序损失

以分数做排序 [机器对样本进行排序, 取得正值做正例, 反例为负例] 逆序数统计

$rank = \frac{1}{m+n} \sum_{i \in D} \sum_{j \in \bar{D}} (I(f(x_i) > f(x_j)) + \frac{1}{2} I(f(x_i) = f(x_j)))$

$m=12, n=6, rank=6$

$AUC = 1 - rank$

证明:

对于书写数字寻找数字5, 阈值 Various thresholds 有12种取法

1. position = odd, 认为样本中不存在正例,  $TPR = \frac{0}{6} = 0, FPR = \frac{0}{6} = 0$

2. ... 12, 认为有1个正例,  $TPR = \frac{1}{6}, FPR = \frac{1}{6}$

3. ... 2, ... 2,  $TPR = \frac{2}{6}, FPR = \frac{2}{6}$

4. ... 3, ... 3,  $TPR = \frac{3}{6}, FPR = \frac{3}{6}$

5. ... 4, ... 4,  $TPR = \frac{4}{6}, FPR = \frac{4}{6}$

6. ... 5, ... 5,  $TPR = \frac{5}{6}, FPR = \frac{5}{6}$

7. ... 6, ... 6,  $TPR = \frac{6}{6}, FPR = \frac{6}{6}$

8. ... 7, ... 7,  $TPR = \frac{6}{6}, FPR = \frac{6}{6}$

9. ... 8, ... 8,  $TPR = \frac{6}{6}, FPR = \frac{6}{6}$

10. ... 9, ... 9,  $TPR = \frac{6}{6}, FPR = \frac{6}{6}$

11. ... 10, ... 10,  $TPR = \frac{6}{6}, FPR = \frac{6}{6}$

12. ... 11, ... 11,  $TPR = \frac{6}{6}, FPR = \frac{6}{6}$

13. ... 12, ... 12,  $TPR = \frac{6}{6}, FPR = \frac{6}{6}$

绘制ROC曲线

多种训练集一种算法

**代价敏感错误率与代价曲线**

二分类代价矩阵

| 真实类别 | 预测类别               |                    |
|------|--------------------|--------------------|
|      | 第1类                | 第0类                |
| 第0类  | 0                  | cost <sub>01</sub> |
| 第1类  | cost <sub>10</sub> | 0                  |

代价敏感错误率为

$E(f; D, cost) = \frac{1}{n} (\sum_{i \in D} I(f(x_i) \neq 1) \times cost_{10} + \sum_{i \in \bar{D}} I(f(x_i) \neq 0) \times cost_{01})$

使用参数方程, 做代价敏感错误率

目的: 对于一个模型, 根据  $\sigma$  (概率) 不同, 找到使得代价总期望最小的模型的阈值

基于正例比例所需, 取值是阈值, 初始样本中初始算法

横轴: 归一化的正概率率代价值  $P(+|cost) = \frac{cost_{01}}{cost_{01} + cost_{10}} \times P(+)$

纵轴: 归一化的总代价值期望  $Cost_{normal} = \frac{cost_{01}}{cost_{01} + cost_{10}} \times P(+)$

代价曲线

False Negative Rate, False Positive Rate, 逆序数统计

$Cost_{normal} = \frac{cost_{01}}{cost_{01} + cost_{10}} \times P(+)$

**偏差与方差**

测试集上的性能在多大程度上保证真实的性能

比较检验

**问题**

1. 测试集上的性能与真正的泛化性能未必相同

2. 测试集不同反映出来的性能不同

3. 机器学习算法本身具有随机性, 同一个测试集上多次运行, 可能会有不同的结果

**一个测试集一种算法**

**二项分布**

常用的离散型随机变量

(1) 0-1随机分布

若随机变量X只有两个可能的取值0和1, 其概率分布为

$P(X=x) = p^x (1-p)^{1-x}, x=0,1$

则称X服从0-1分布

(2) 二项分布

设事件A在任意一次实验中出现的概率是p ( $0 < p < 1$ ), X表示n重伯努利试验中发生的次数, 则X的所有可能取值为0, 1, 2, 3, ..., n, 且相应概率为

$P(X=k) = C_n^k p^k (1-p)^{n-k}, k=0,1,2,\dots,n$

**假设检验**

从测试集中找出  $m$  个数, 若与图像出入太大, 说明假设错误, 可以拒绝假设

若与图像接近, 则不能拒绝假设

具体的, 若置信区间为90%, 则当测试集中测得的错误样本数落在置信区间时, 则无法拒绝假设

之所以要回到二项分布, 正态分布等标准分布, 是因为它们的面积好求

**多个测试集一种算法**

t检验

离散型随机变量的函数分布

卡方分布

t分布

正态分布与处理t分布

假设同一模型有3个测试集  $T_1, T_2, T_3$ , 样本  $m=10$ , 它们分别有各自的错误率  $\hat{e}_1, \hat{e}_2, \hat{e}_3$  对它们进行排列组合

则它们每个的概率分布都是

各自错误样本数

二项分布

假设  $\epsilon = 0.3$  输出错误率分布 ( $n \rightarrow \infty$ )

若假设的错误率是一个范围, 如  $\epsilon \leq 0.3$  对于这个假设, 实际只设了上限, 拒绝这个假设的办法只能是出现大于某个数的错误

概率累加和  $\sum_{i=1}^n P(X=i)$

置信区间90%

多个测试集多种算法

交叉验证t检验

一个测试集两种算法

McNemar检验

多个测试集多种算法

Friedman与Nemeny后续检验