

模型评估与选择

一種訓練集一種算法

經驗误差与过拟合

使用模型對m样本進行預測
模型得到一个預測函數 $f_m = \hat{y}$ (預測值)，而样本的正确結果為Y
則有錯誤率 $E = \frac{a}{m}$
精度 $1 - E$
误差 $|Y - \hat{y}|$

評估方法

泛化能力

模型對沒有見過的數據的預測能力
訓練集vs測試集

訓練集

留出法
很簡單的三七分、二八分
注意訓練集與測試集同分布
或進行多次隨機劃分、訓練出多個模型，最後取均值

測試集的保留方法

交叉驗證法
K折交叉驗證
缺點：數據量較大時，對算力要求高


自助法
原理：通過自助採樣，初始數據集D中約有36.8%的樣本未出現在採樣數據集D中，可將D'用作訓練集，D\D'作為測試集
適用於數據集較小，難以劃分時
缺點：改變初始數據集分布，會引入估計偏差



將D劃分為n個數據集
每次取其中一個作為測試集，其它用於訓練
取n個測試結果的平均值作為該模型的結果

驗證集

為了調參，經常在數據集中再劃分一部分作為驗證集，流程為



性能度量

任務描述

給定樣本集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$
其中 y_i 是 x_i 的真實標記。要評價學習器f的性能，就要把學習器預測結果 $f(x)$ 與真實標記y進行比較

均方误差

回歸任務最常用的性能度量是“均方误差”
 $E(f, D) = \frac{1}{m} \sum_{i=1}^m (f(x_i) - y_i)^2$ [根據分布一致則]
更一般地，對於數據分布D和概率密度函數p(x)，均方误差可描述為 $E(f, D) = \int_{x \in D} (f(x) - y)^2 p(x) dx$

錯誤率与精度

錯誤率: $E(f, D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(x_i) \neq y_i)$ 其中 $\mathbb{I}(\cdot)$ 為指示函數，始末的值為真則取1，否則為0
精度: $acc(f, D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(x_i) = y_i) = 1 - E(f, D)$

混淆矩陣

True Positive 真正例
False Positive 假正例
True Negative 真反例
False Negative 假反例


實際 \ 預測結果		預測結果	
值	正例	TP	FN
	反例	FP	TN

查准率 查全率 和 F1 值

P-R 曲線

查准率 $P = \frac{TP}{TP + FP}$ 也叫精確率
查全率 $R = \frac{TP}{TP + FN}$ 也叫召回率

舉例說明：
手寫數字識別：使用機器分類是5還是非5（機器對每個樣本進行打分，分最高的約容易被判斷為正例）
實際上是隨著閾值的移動，P、R呈反向變動
模型生成了一個值用於判斷樣本是真是假。隨著該值的變化，得到的R、P會呈反向變動



最優閾值的確定

1. 使用平衡點 (即 $P = R$ 時)

多數時候，往往只需TP的占比情況，我們希望能提高TP的權重，故設定了
一個調和平均數 $F_1 = \frac{2PR}{P+R}$
其中 $\frac{1}{F_1} = \frac{1}{2}(\frac{1}{P} + \frac{1}{R}) \Rightarrow F_1 = \frac{2PR}{P+R}$

2. F_1 度量

F_1 是基於查准率和查全率的調和平均數定義的
 F_β 則是加權調和平均: $F_\beta = \frac{2\beta PR}{\beta^2 P + P + R}$ [$\frac{1}{F_\beta} = \frac{1}{\beta}(\frac{1}{P} + \beta^2 \frac{1}{R})$]

其中 $\beta > 0$ 度量了查全率對查准率的相對重要性， $\beta = 1$ 時退化為標準的 F_1 ； $\beta > 1$ 時查全率有更大的影響； $\beta < 1$ 時查准率有更大影響

與算數平均 $\frac{P+R}{2}$ 和幾何平均 \sqrt{PR} 相比，調和平均
均更重視較小值

先分別計算，再求平均值

$(P_1, R_1), (P_2, R_2), \dots, (P_n, R_n)$
macro-P 宏查准率: $macro-P = \frac{1}{n} \sum_{i=1}^n P_i$
macro-R 宏查全率: $macro-R = \frac{1}{n} \sum_{i=1}^n R_i$
macro-F1 宏 F1: $macro-F1 = \frac{2 \times macro-P \times macro-R}{macro-P + macro-R}$

n 個二分類實現的多分類問題

光看 TP, FP, TN, FN


一种训练多种算法

n个二分类实现的多分类问题

先平均再计算

$$MARCO - F1 \geq F1$$
$$MARCO - F1 = \frac{2 \times MARCO \times F1}{MARCO + F1}$$
$$MARCO - R = \frac{2 \times MARCO \times R}{MARCO + R}$$
$$MARCO - F1 = \frac{2 \times MARCO \times F1}{MARCO + F1}$$
$$MARCO - R = \frac{2 \times MARCO \times R}{MARCO + R}$$

P-R曲线



比较ABC 3个模型的好坏

首先可以确定B和A优于C，BA之间有交叉，无法确定

对比AB

- 方法1: 比较AB的面积大小，在一定程度上表征了模型的优劣，但是这个值不容易估算
- 方法2: $F1$
- 方法3: $F1$


ROC与AUC

ROC


True Positive Rate: $TPR = \frac{TP}{TP+FN}$
False Positive Rate: $FPR = \frac{FP}{TN+FP}$

真实值	预测值	
	正例	反例
正例	TP	FN
反例	FP	TN

示意图



基于有限样例绘制



AUC: Area Under ROC Curve 即ROC曲线下的面积

$$AUC = \frac{1}{2} \sum_{i=1}^m (x_{i+1} - x_i)(y_{i+1} + y_i)$$

AUC

排序损失

形式化地看，AUC考虑的是样本预测的排序质量，因此它与排序误差有紧密联系。

给定 m' 个正例和 m'' 个反例，令 D^+, D^- 表示正反例集合

则排序损失定义为 $(rank = \frac{1}{m'm''} \sum_{x' \in D^+} \sum_{x'' \in D^-} (\mathbb{I}(f(x') < f(x'')) + \frac{1}{2} \mathbb{I}(f(x') = f(x''))))$


以手写数字为例（机器对样本进行排序，越往左分值越低，反之越高），得到逆序数为4



$rank = \frac{4}{6} = \frac{2}{3}$
 $m = 12, m' = 6, m'' = 6$

真实值	预测值	
	正例	反例
正例	TP	FN
反例	FP	TN


对于书写数字寻找数字5，阈值 Various thresholds 有12种取法



1. position = 0.0. 认为样本中不存在正例, $TPR = 0, FPR = 0$

- 2. ... 1. 认为只有1个正例 $TPR = \frac{1}{6}, FPR = \frac{1}{6}$
- 3. ... 2. $TPR = \frac{2}{6}, FPR = \frac{2}{6}$
- 4. ... 3. $TPR = \frac{3}{6}, FPR = \frac{3}{6}$
- 5. ... 4. $TPR = \frac{4}{6}, FPR = \frac{4}{6}$
- 6. ... 5. $TPR = \frac{5}{6}, FPR = \frac{5}{6}$
- 7. ... 6. $TPR = \frac{6}{6}, FPR = \frac{6}{6}$
- 8. ... 7. $TPR = \frac{7}{6}, FPR = \frac{7}{6}$
- 9. ... 8. $TPR = \frac{8}{6}, FPR = \frac{8}{6}$
- 10. ... 9. $TPR = \frac{9}{6}, FPR = \frac{9}{6}$
- 11. ... 10. $TPR = \frac{10}{6}, FPR = \frac{10}{6}$
- 12. ... 11. $TPR = \frac{11}{6}, FPR = \frac{11}{6}$
- 13. ... 12. $TPR = \frac{12}{6}, FPR = \frac{12}{6}$

绘制ROC曲线



$AUC = 1 - rank = 1 - \frac{4}{6} = \frac{2}{3}$

代价敏感错误率与代价曲线

二分类代价矩阵

真实类别	预测类别	
	第0类	第1类
第0类	0	cost ₀₁
第1类	cost ₁₀	0

代价敏感错误率为

$$E(f; D; cost) = \sum_{x \in D} (\mathbb{I}(f(x) \neq y_x) \times cost_{01} + \mathbb{I}(f(x) \neq y_x) \times cost_{10})$$

代价曲线

目的: 对于一个模型，根据p（概率）不同，找到使得代价总期望最小的模型的阈值

横轴: 归一化的正概率代期望 $P(+|cost) = p \times cost_{01} + (1-p) \times cost_{10}$

纵轴: 归一化的总代期望 $cost_{normal} = p \times cost_{01} + (1-p) \times cost_{10}$

TP	FN
FP	TN

偏差与方差

多种训练集一种算法

- 问题
- 1.测试集上的性能与真正的泛化性能未必相同
 - 2.测试集不同反映出来的性能不同
 - 3.机器学习算法本身具有随机性，同一个测试集上多次运行，可能会有不同的结果

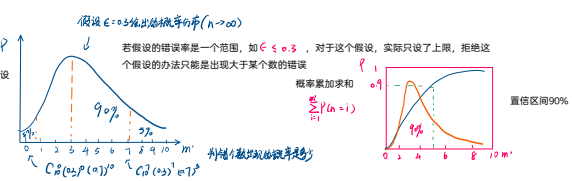
假设测试集有m个样本，其中判断错误的有m'个，可知错误率 $\hat{e} = \frac{m'}{m}$
 在所有的真实数据中，假设其错误率为 \bar{e} ，若测试集中m=10，则m'=?

一个测试集一种算法

常用的离散型随机变量
 (1) 0-1随机分布
 若随机变量X只有两个可能的取值0和1，其概率分布为
 $P(X=x_i) = p^{x_i}(1-p), x_i = 0, 1$
 则称X服从0-1分布
 (2) 二项分布
 设事件A在任意一次实验中出现的概率是p (0<p<1), X表示n重伯努利试验中发生的次数，则X的所有可能取值为0,1,2,3,...,n，且相应概率为
 $P(X=k) = C_n^k p^k (1-p)^{n-k}, k=0,1,2,...,n$

假设检验

从测试集中找出m'的个数，若与图像出入太大，说明假设错误，可以拒绝假设
 若与图像接近，则不能拒绝假设；
 具体的，若置信区间为90%，则当测试集中测得的错误样本数量落在置信区间时，则无法拒绝假设
 之所以要归到二项分布、正态分布等标准分布，是因为它们的面积好求



多个测试集一种算法 t检验

离散型随机变量的函数分布
 卡方分布
 t分布
 正态分布与处理为t分布

假设同一个模型有3个测试集 $\bar{e}_1, \bar{e}_2, \bar{e}_3$ ，样本m=10，它们分别有各自的错误率 $\hat{e}_1, \hat{e}_2, \hat{e}_3$ ，对它们进行排列组合各自错误样本数

\bar{e}_{test1}	0	0	0	...	10
\bar{e}_{test2}	0	0	1	...	10
\bar{e}_{test3}	0	1	1	...	10

多个测试集两种算法 交叉验证t检验
 一个测试集两种算法 McNemar检验
 多个测试集多种算法 Friedman与Nemenyi后续检验

由于是独立事件，每个之间都是用乘法求的概率
 得到的错误率 \bar{e} 与方差 σ^2 共有n!个，重复的需要合并，得到新的概率分布
 又回归到1个测试集1种算法的问题

测试集上的性能在多大程度上保证真实的性能比较检验