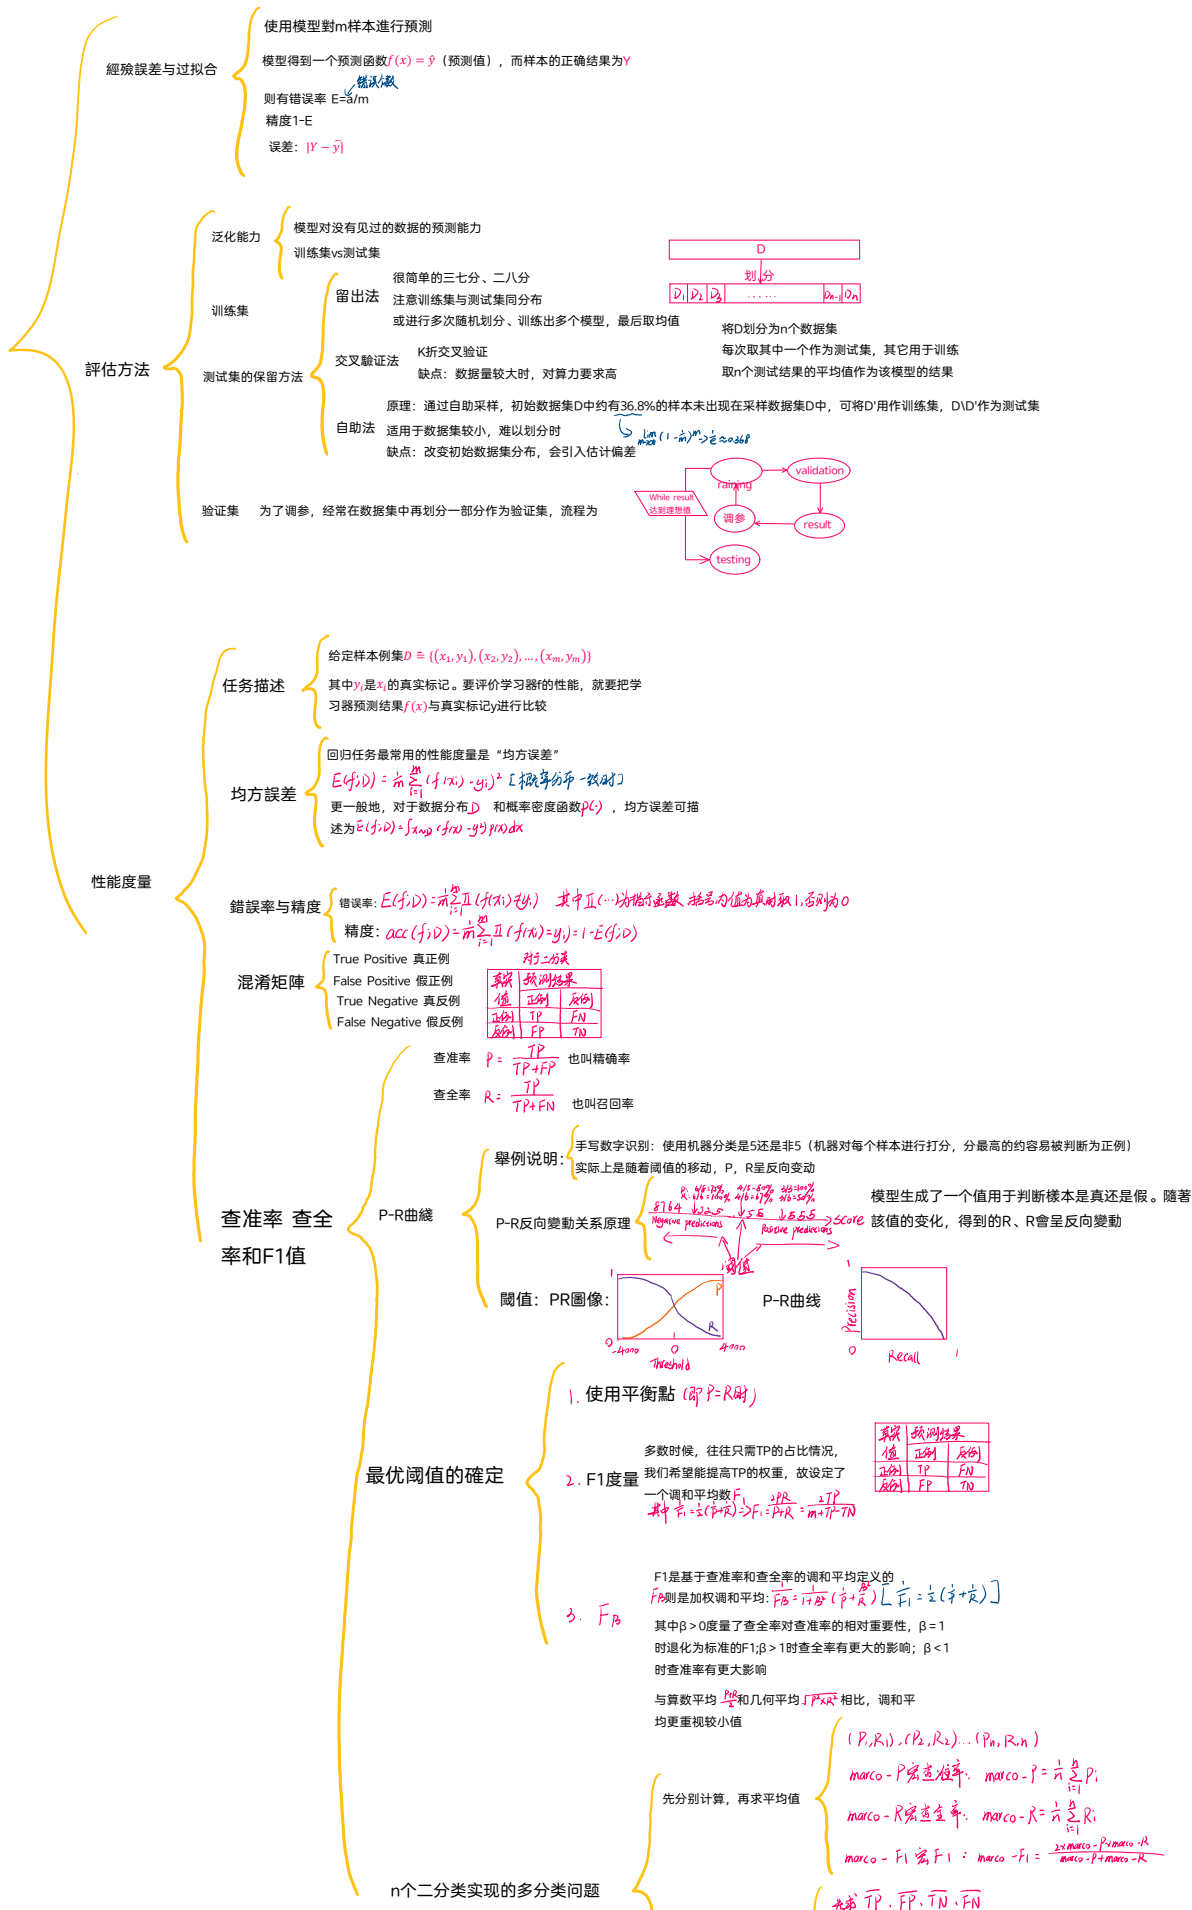


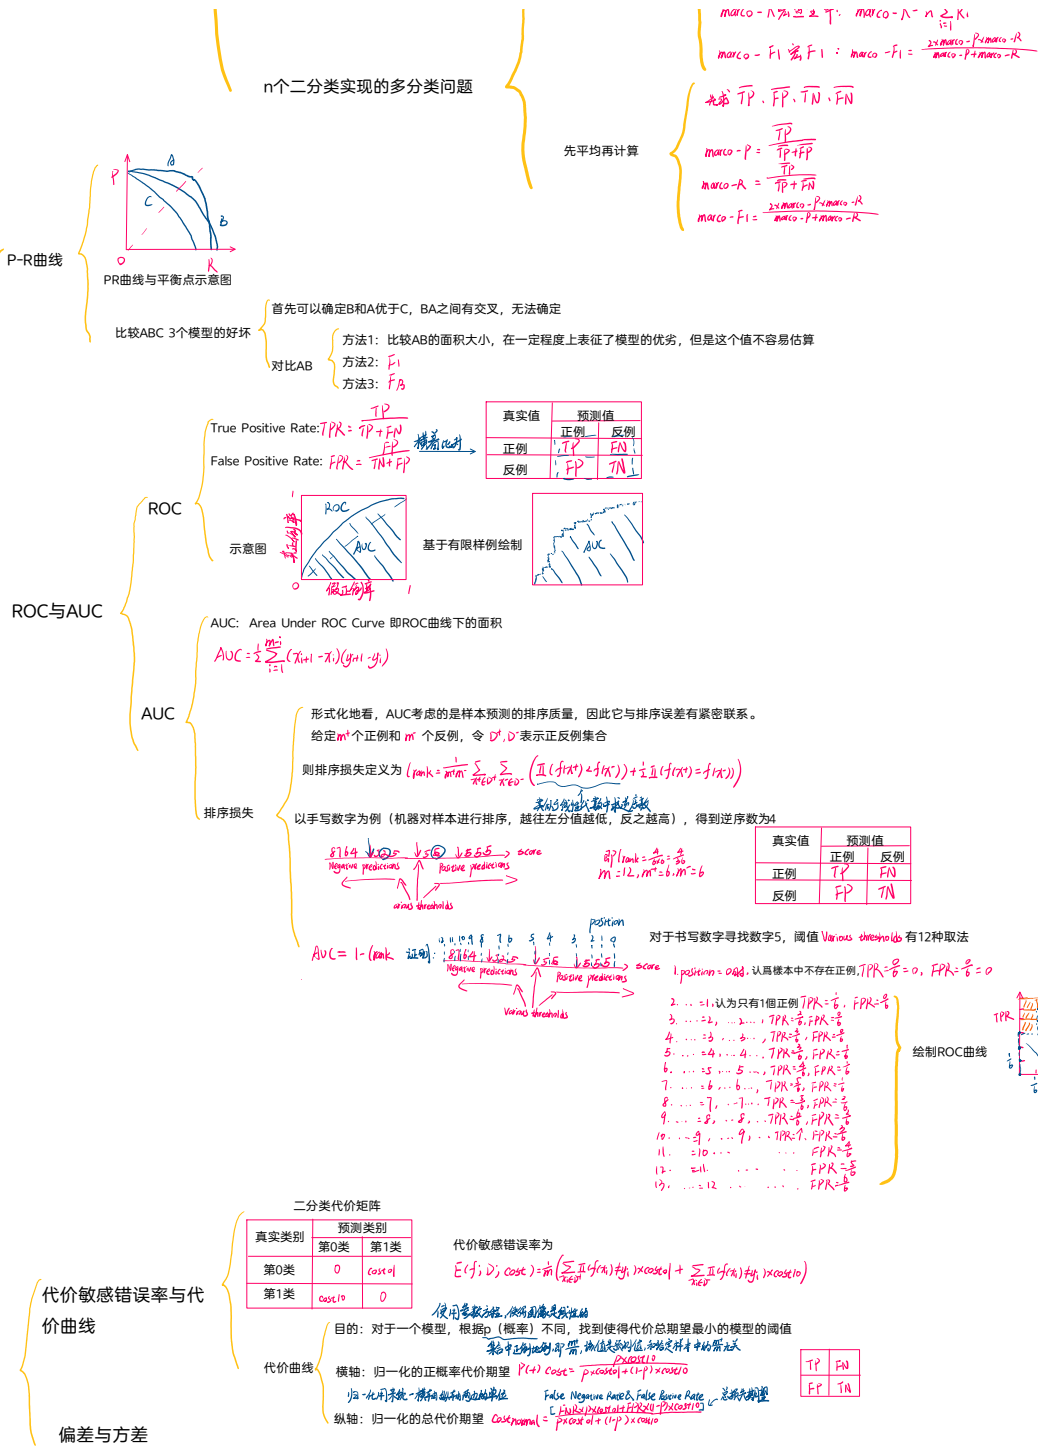
模型评估与选择

一種訓練集一種算法



一种训练多种算法

多种训练集一种算法



测试集上的性能在多大程度上保证真实的性能比较检验

问题

1.测试集上的性能与真正的泛化性能未必相同

2.测试集不同反映出来的性能不同

3.机器学习算法本身具有随机性，同一个测试集上多次运行，可能会有不同的结果

一个测试集一种算法

假设测试集有m个样本，其中判断错误的有m'个，可知错误率 $\hat{e} = \frac{m'}{m}$

在所有的真实数据中，假设其错误率为 \hat{e}_0 ，若测试集中m=10，则m'=?

二项分布

常用的离散型随机变量

(1) 0-1随机分布

若随机变量X只有两个可能的取值0和1，其概率分布为

$P(X=x_i) = p^{x_i}(1-p)^{1-x_i}, x_i \in \{0, 1\}$

则称X服从0-1分布

(2) 二项分布

设事件A在任意一次实验中出现的概率是p (0<p<1), X表示n重伯努利试验中发生的次数，则X的所有可能取值为0,1,2,...,n，且相应概率为

$P(X=k) = C_n^k p^k (1-p)^{n-k}, k=0,1,2,...,n$

假设检验

从测试集中找出m'的个数，若与图像出入太大，说明假设错误，可以拒绝假设

若与图像接近，则不能拒绝假设

具体的，若置信区间为90%，则当测试集中测得的错误样本数量落在置信区间时，则无法拒绝假设

之所以要归到二项分布、正态分布等标准分布，是因为它们的面积好求

假设 $\hat{e} = 0.2$ 输出错误率分布($n \rightarrow \infty$)

若假设的错误率是一个范围，如 $\hat{e} \leq 0.5$ ，对于这个假设，实际只设了上限，拒绝这个假设的办法只能是出现大于某个数的错误

概率累加求和 $\sum_{i=0}^k P(n=i)$

置信区间90%

外推个数输出错误率是少

多个测试集一种算法 t检验

离散型随机变量的函数分布

卡方分布

t分布

正态分布与处理为t分布

假设同一个模型有3个测试集 J_1, J_2, J_3 ，样本m=10，它们分别有各自的错误率 $\hat{e}_1, \hat{e}_2, \hat{e}_3$ ，对它们进行排列组合

则它们每个的概率分布都是

二项分布

Test1	0	0	0			10
Test2	0	0	1	...		10
Test3	0	1	1			10

由于是独立事件，每个之间都是用乘法求的概率

得到的错误率 \hat{e} 与方差 σ^2 共有n^4个，重复的需要合并，得到新的概率分布

又回归到1个测试集1种算法的问题

多个测试集两种算法

交叉验证t检验

一个测试集两种算法

McNemar检验

多个测试集多种算法

Friedman与Nemeny后续检验