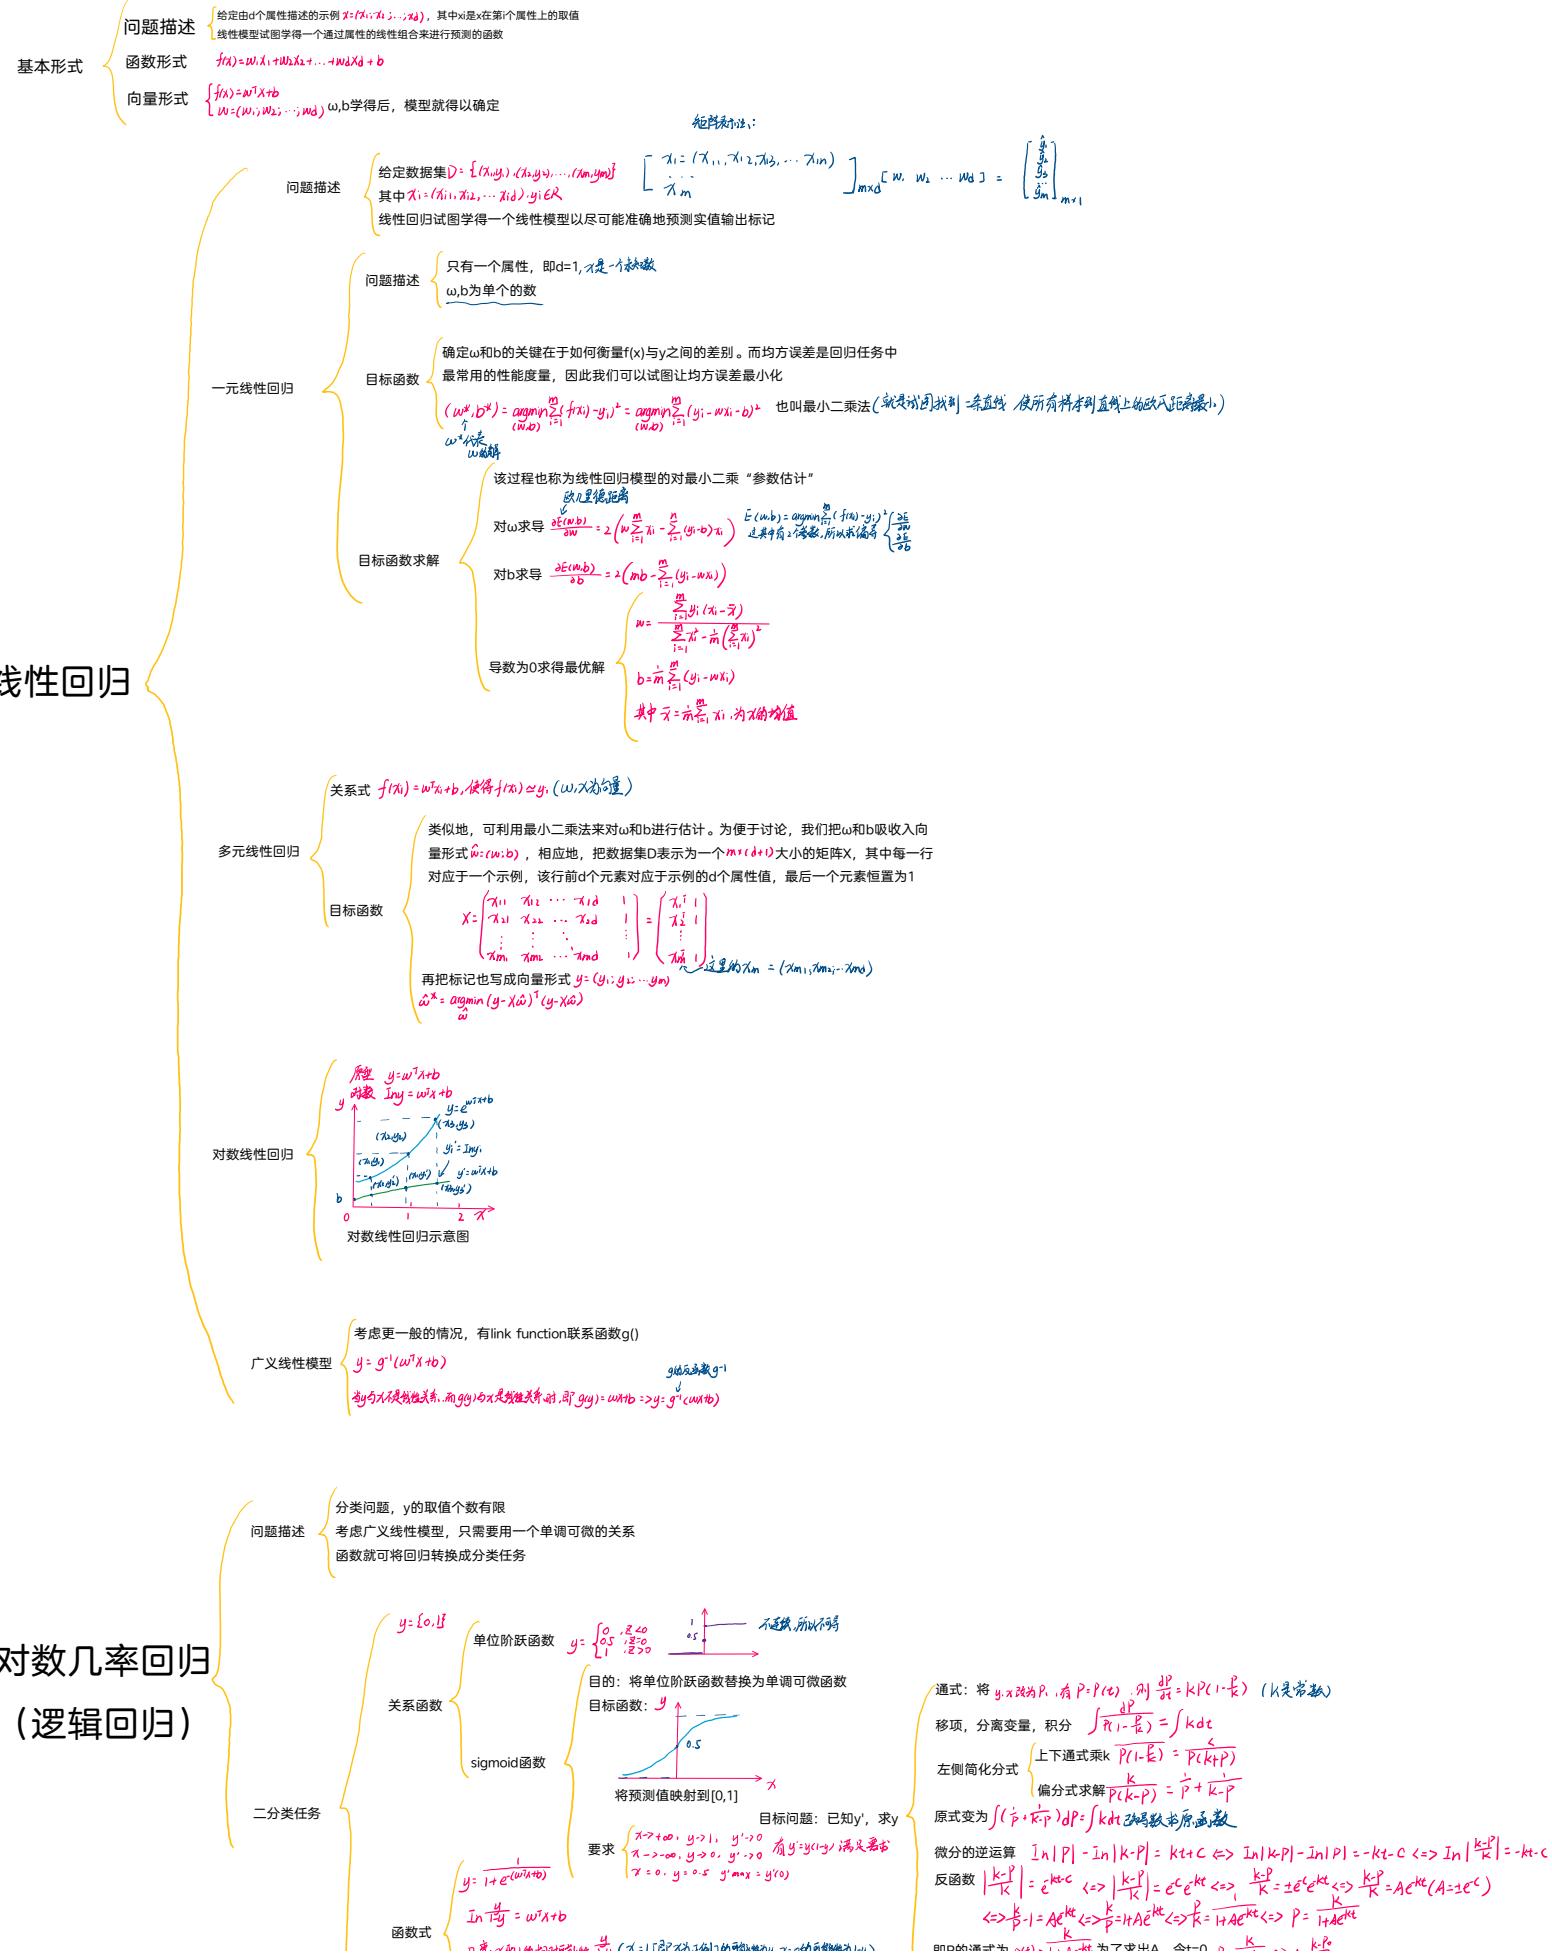
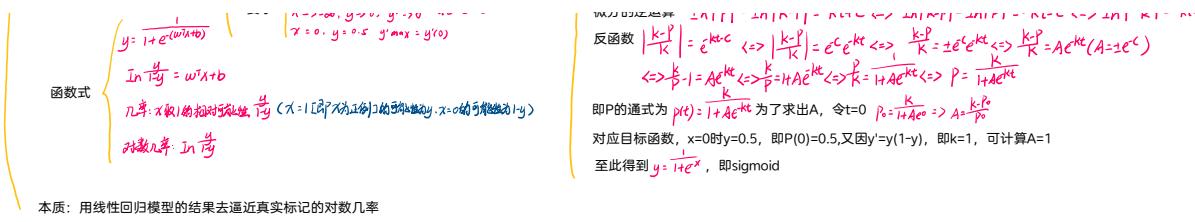
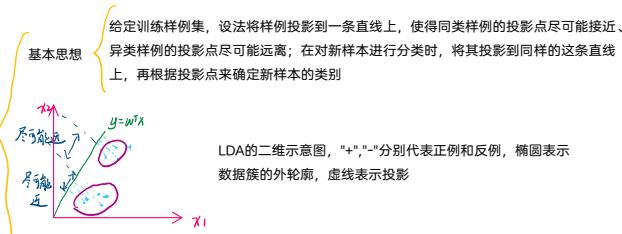


# 线性模型

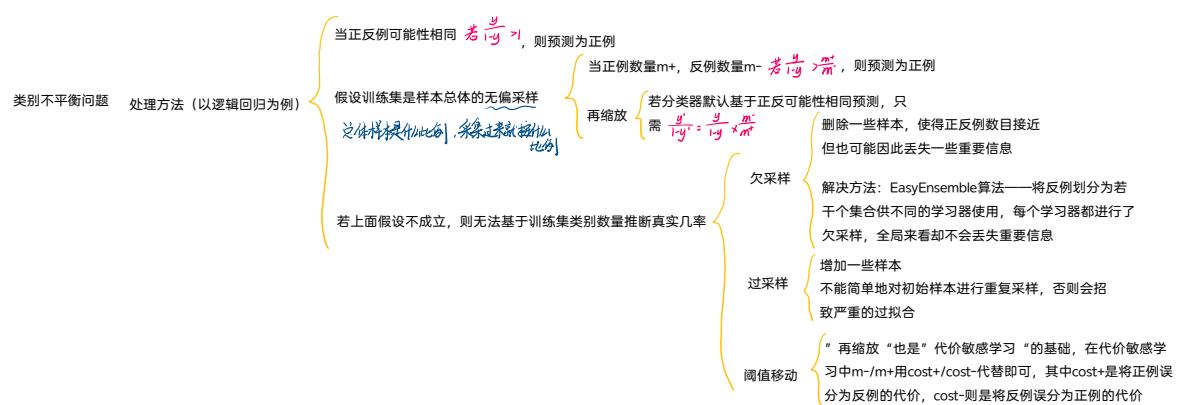




## LDA线性判断分析



多分类学习---拆解法: 拆分为若干个二分类



## 梯度下降

基本思想

已知样本集  $X$ , 预测函数  $f(x) = w^T x + b$   
对预测值和真实值作差得到损失函数  $loss = -y \cdot f(x)$   
若把  $f(x)$  表现为矩阵形式 (表现为  $\theta$ ) , 则有  $loss = -y \cdot h(\theta)$   
欲求 loss 的最小值, 即对  $h(\theta)$  求导  
 $\frac{\partial h(\theta)}{\partial \theta} = 0$ ,  $\theta$  就是要找的极值

但对高维空间求导比较困难, 可考虑以下方法  
任意给定  $\theta$  一个初始值, 解出该值下的  $loss$  和  $h(\theta)$   
若  $h(\theta)$  说明函数此时在上升, 所以需要将  $\theta$  回退几个单位, 直到  $h(\theta)$  接近或等于 0  
如若  $h(\theta) > 0$  时, 则  $\theta' = \theta - h(\theta)$  且 学得, 但被  
回退后再次求的  $loss$  和  $h(\theta)$  并循环往复  
直到 loss 值小到我们可接受的范围或  $h(\theta)$  越接近 0

批量梯度下降

将上述问题扩展到多维时, 就需要对每一个方向都求偏导 (梯度)  

$$\frac{\partial}{\partial \theta_j} MSE(\theta) = \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)}, y^{(i)}) x_j^{(i)}$$

$$\text{损失函数对参数的偏导 } \nabla_{\theta_j} MSE(\theta) = \begin{pmatrix} \frac{\partial}{\partial \theta_1} MSE(\theta) \\ \vdots \\ \frac{\partial}{\partial \theta_n} MSE(\theta) \end{pmatrix} = \frac{1}{m} X^T (X\theta - y)$$

$$\text{参数更新 } \theta^{(\text{next step})} = \theta - \eta \nabla_{\theta} MSE(\theta)$$

要求所有的方向都求出偏导后, 才算走了一步, 所以处理速度较慢

随机梯度下降

每次随机随机选择一个方向, 每次迭代处理的数据很少, 处理速度高  
达到最小值不会稳定下来, 会继续弹跳, 因此算法停止时, 最终的参数是一个比较好的参数, 但不是最佳的

学习率(Learning Rate)

参数更新时, 需要选择合适的学习率。若学习率太低, 处理数据速度会变慢; 如果太高, 容易掠过最低点  
寻找合适的学习率

- 网格搜索 使用网格搜索, 设定迭代次数, 尝试几种可能的参数, 比较结果, 选择最优
- 梯度限制 设置大量的迭代, 当梯度向量变小于一个值时停止

局部最优和全局最优

有些时候我们找到的点可能只是局部最优, 还需要添加其他的参数辅助查找全局最优。但一般情况下, 只要该局部最优点的损失是在可控范围内就可以了