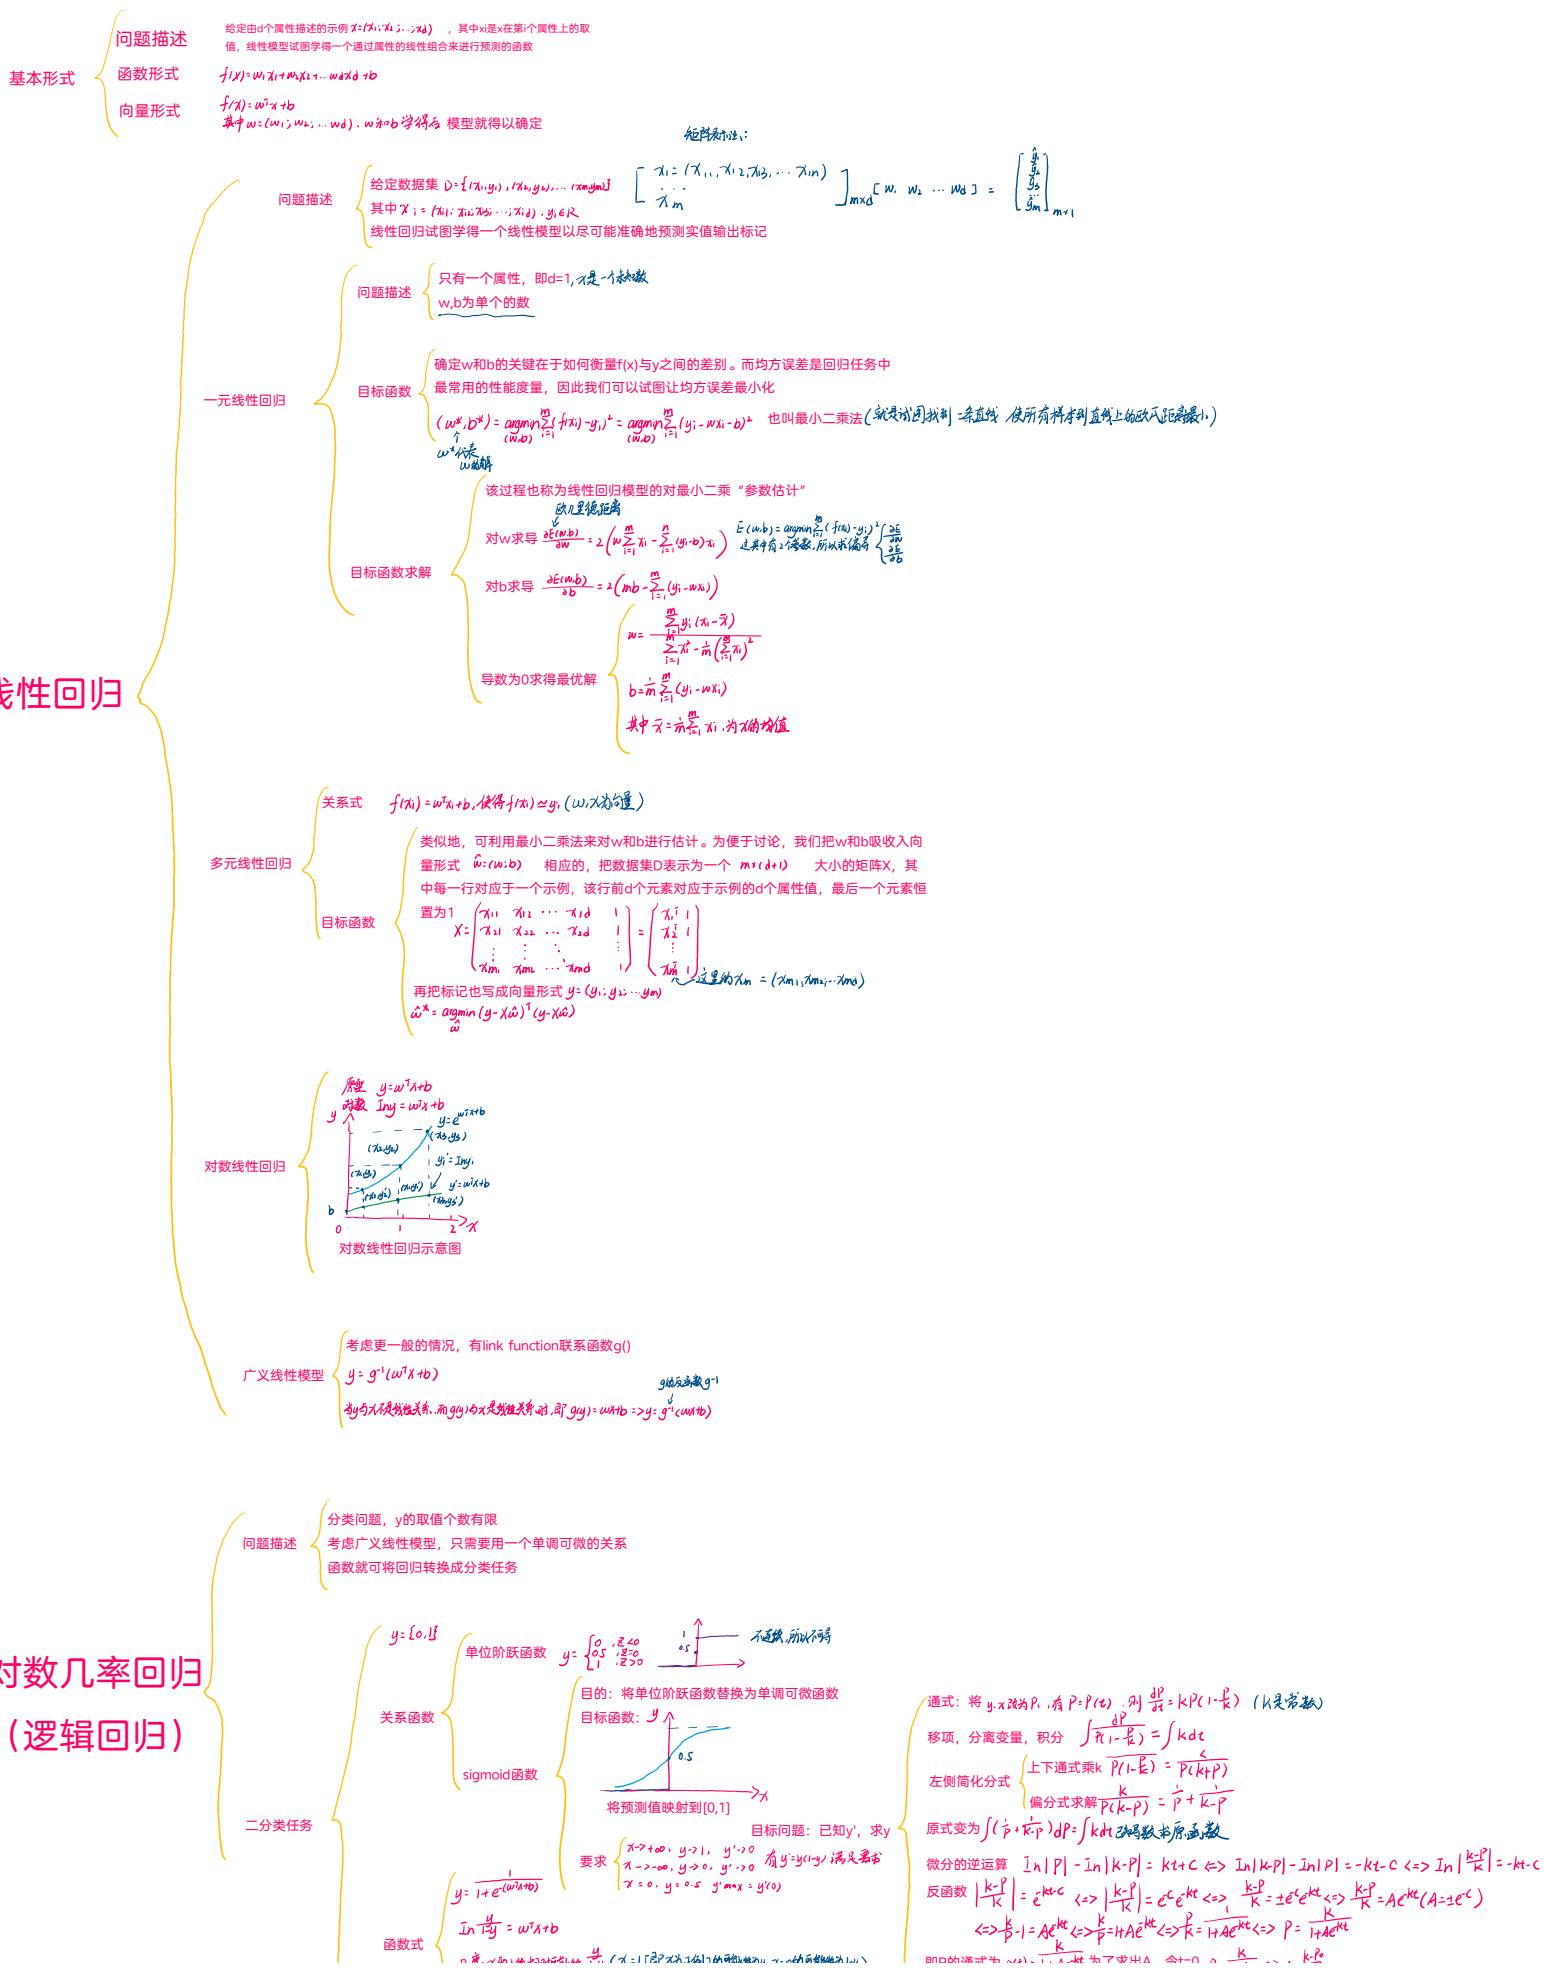
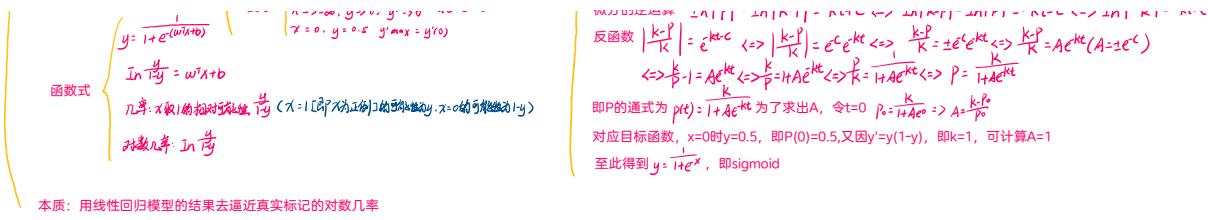
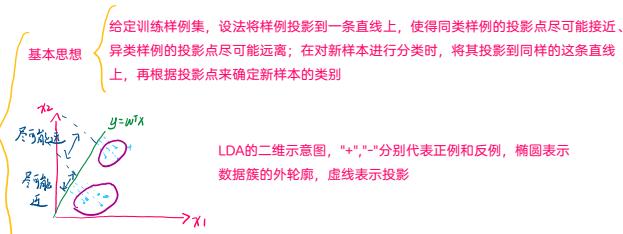


线性模型

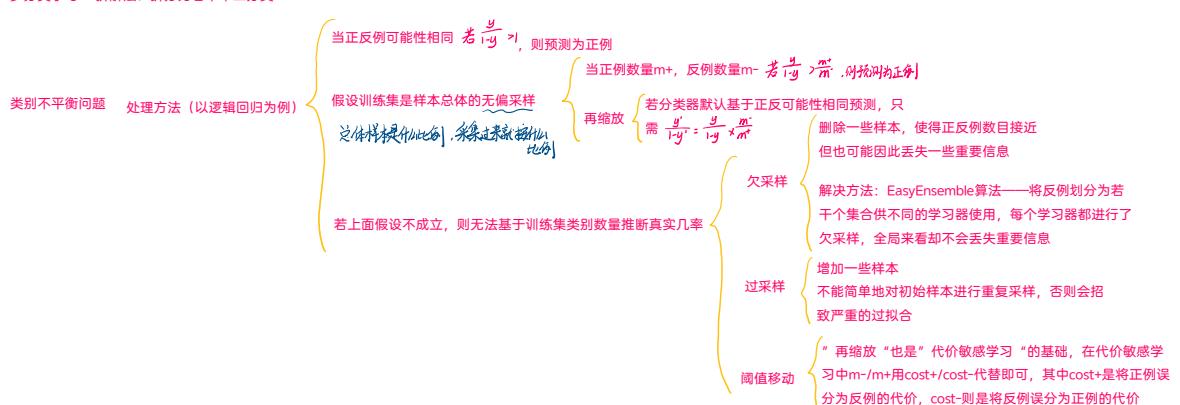




LDA线性判断分析



多分类学习---拆解法：拆分为若干个二分类



梯度下降

基本思想

已知样本集 X ，预测函数 $f(x) = w^T x + b$
对预测值和真实值作差得到损失函数 $loss = |Y - f(x)|$
若把 $loss$ 改成平方形式（梯度下降），则有 $loss = (Y - f(x))^2$
欲求 $loss$ 的最小值，即对 $f(\theta)$ 求导
若 $f'(\theta) = 0$ ， θ 就是想找的极值

但对于高维空间求导比较困难，可考虑以下方法
任意给定一个初始值，解出该值下的 $loss$ 和 $f'(\theta)$
若 $f'(\theta) > 0$ ，说明函数此时在上升，所以需要将 θ 回退几个单位，直到 $f'(\theta)$ 接近或等于 0
如果 $f'(\theta) < 0$ ，回退后的 $\theta' = \theta - f'(\theta) \cdot \eta$ 学步，可继续
回退后再次求的 $loss$ 和 $f'(\theta)$ 并循环往复
直到 $loss$ 小到我们可接受的范围或 $f'(\theta)$ 越接近 0

批量梯度下降

将上述问题扩展到多维时，就需要对每一个方向都求偏导（梯度）

$$\frac{\partial}{\partial \theta_j} MSE(\theta) = \frac{1}{m} \sum_{i=1}^m (f(\theta)^{(i)} - y^{(i)}) \cdot \frac{\partial}{\partial \theta_j} f(\theta)^{(i)}$$

$$\text{损失函数对参数的偏导 } \nabla \theta_j MSE(\theta) = \left(\frac{\partial}{\partial \theta_1} MSE(\theta), \frac{\partial}{\partial \theta_2} MSE(\theta), \dots, \frac{\partial}{\partial \theta_n} MSE(\theta) \right)$$

参数更新 $\theta^{(next step)} = \theta - \eta \nabla \theta MSE(\theta)$

要求所有的方向都求出偏导后，才算走了一步，所以处理速度较慢

随机梯度下降

每次随机随机选择一个方向，每次迭代处理的数据很少，处理速度高
达到最小值不会稳定下来，会继续弹跳，因此算法停止时，最终的参数是一个比较好的参数，但不是最佳的

学习率(Learning Rate)

参数更新时，需要选择合适的学习率。若学习率太低，处理数据速度会变慢；如果太高，容易掠过最低点
寻找合适的学习率

- 网格搜索 使用网格搜索，设定迭代次数，尝试几种可能的参数，比较结果，选择最优
- 梯度限制 设置大量的迭代，当梯度向量变小于一个值时停止

局部最优和全局最优

有些时候我们找到的点可能只是局部最优，还需要添加其他参数辅助查找全局最优。但一般情况下，只要该局部最优点的损失是在可控范围内就可以了