

基本形式

- 问题描述: 给定由d个属性描述的示例  $X = \{x_1, x_2, \dots, x_d\}$  其中  $x_i$  是  $x$  在第  $i$  个属性上的取值, 线性模型试图学得一个通过属性的线性组合来进行预测的函数
- 函数形式:  $f(x) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$
- 向量形式:  $f(x) = w^T x + b$   
其中  $w = (w_1, w_2, \dots, w_d)$ ,  $w$  和  $b$  学得后, 模型就得以确定

矩阵表示法:

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} \begin{bmatrix} w_1 & w_2 & \dots & w_d \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}_{m \times 1}$$

问题描述: 给定数据集  $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$  其中  $x_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{id})$ ,  $y_i \in \mathbb{R}$  线性回归试图学得一个线性模型以尽可能准确地预测实值输出标记

问题描述: 只有一个属性, 即  $d=1$ , 不是一个函数  $w, b$  为单个的数

目标函数: 确定  $w$  和  $b$  的关键在于如何衡量  $f(x)$  与  $y$  之间的差别, 而均方误差是回归任务中最常用的性能度量, 因此我们可以试图让均方误差最小化

$$(w^*, b^*) = \underset{(w, b)}{\operatorname{argmin}} \sum_{i=1}^m (f(x_i) - y_i)^2 = \underset{(w, b)}{\operatorname{argmin}} \sum_{i=1}^m (y_i - w x_i - b)^2 \quad \text{也叫最小二乘法 (就是试图找到一条直线, 使所有样本到直线上的欧氏距离最小)}$$

该过程也称为线性回归模型的对最小二乘“参数估计”

欧氏距离

$$\text{对 } w \text{ 求导 } \frac{\partial E(w, b)}{\partial w} = 2 \left( w \sum_{i=1}^m x_i - \sum_{i=1}^m (y_i - b) x_i \right)$$

$$E(w, b) = \underset{(w, b)}{\operatorname{argmin}} \sum_{i=1}^m (f(x_i) - y_i)^2 \quad \begin{cases} \frac{\partial E}{\partial w} = 0 \\ \frac{\partial E}{\partial b} = 0 \end{cases}$$

$$\text{对 } b \text{ 求导 } \frac{\partial E(w, b)}{\partial b} = 2 \left( m b - \sum_{i=1}^m (y_i - w x_i) \right)$$

$$\text{导数为0求得最优解} \quad \begin{cases} w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - m \left( \sum_{i=1}^m x_i \right)^2} \\ b = \frac{1}{m} \sum_{i=1}^m (y_i - w x_i) \end{cases}$$

其中  $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$  为  $x$  的均值


$$\text{关系式: } f(x_i) = w x_i + b, \text{ 使得 } f(x) \approx y, (w, x \text{ 为向量})$$

目标函数: 类似地, 可利用最小二乘法来对  $w$  和  $b$  进行估计。为便于讨论, 我们把  $w$  和  $b$  吸收入向量形式  $\hat{w} = (w, b)$  相应的, 把数据集  $D$  表示为一个  $m \times (d+1)$  大小的矩阵  $X$ , 其中每一行对应于一个示例, 该行前  $d$  个元素对应于示例的  $d$  个属性值, 最后一个元素恒置为 1

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1d} & 1 \\ x_{21} & x_{22} & \dots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{md} & 1 \end{bmatrix} = \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_m^T \end{bmatrix}$$

这里的  $x_m = (x_{m1}, x_{m2}, \dots, x_{md})$

$$\hat{w}^* = \underset{\hat{w}}{\operatorname{argmin}} (y - X \hat{w})^T (y - X \hat{w})$$



广义线性模型: 考虑更一般的情况, 有 link function 联系函数  $g()$   
 $y = g^{-1}(w^T x + b)$   
若  $y$  不是线性关系, 而  $g(y)$  与  $x$  是线性关系时, 则  $g(y) = w^T x + b \Rightarrow y = g^{-1}(w^T x + b)$   
链式法则  $g^{-1}$

对数几率回归 (逻辑回归)

问题描述: 分类问题,  $y$  的取值个数有限  
考虑广义线性模型, 只需要用一个单调可微的关系函数就可将回归转换成分类任务

$$y \in \{0, 1\}$$

单位阶跃函数:  $y = \begin{cases} 0 & x < 0 \\ 0.5 & x = 0 \\ 1 & x > 0 \end{cases}$  不连续, 所以不好

sigmoid函数

目的: 将单位阶跃函数替换为单调可微函数

目标函数:

将预测值映射到  $[0, 1]$ 目标问题: 已知  $y$ , 求  $y$ 要求:  $\begin{cases} x \rightarrow +\infty, y \rightarrow 1, y' \rightarrow 0 \\ x \rightarrow -\infty, y \rightarrow 0, y' \rightarrow 0 \\ y = 0.5, y' = \max y'(x) \end{cases}$  满足要求

$$y = \frac{1}{1 + e^{-(w^T x + b)}}$$

$$\ln y = \ln \frac{1}{1 + e^{-(w^T x + b)}} = w^T x + b$$

注意:  $x$  和  $y$  在  $0$  和  $1$  之间,  $x$  和  $y$  在  $0$  和  $1$  之间的可能值  $w$  和  $b$  的可能值  $1$  和  $0$ 通式: 将  $y, x$  改为  $P$ , 有  $P = P(x)$ , 则  $\frac{dP}{dx} = P(1-P)$  ( $k$  是常数)移项, 分离变量, 积分  $\int \frac{dP}{P(1-P)} = \int k dx$ 左侧简化分式:  $\frac{1}{P(1-P)} = \frac{1}{P} + \frac{1}{1-P}$ 偏分式求解  $\frac{1}{P(1-P)} = \frac{1}{P} + \frac{1}{1-P}$ 原式变为  $\int \left( \frac{1}{P} + \frac{1}{1-P} \right) dP = \int k dx$  微分求原函数微分的逆运算  $\ln |P| - \ln |1-P| = kx + C \Leftrightarrow \ln \left| \frac{P}{1-P} \right| = kx + C \Leftrightarrow \left| \frac{P}{1-P} \right| = e^{kx+C} = e^C e^{kx} \Leftrightarrow \frac{P}{1-P} = A e^{kx} (A = \pm e^C)$ 反函数  $\left| \frac{P}{1-P} \right| = e^{kx+C} \Leftrightarrow \frac{P}{1-P} = e^C e^{kx} \Leftrightarrow \frac{P}{1-P} = A e^{kx} \Leftrightarrow P = \frac{A e^{kx}}{1 + A e^{kx}}$   
Ehosh的统计为  $(n-1) \cdot \frac{1}{1 + A e^{kx}}$  为了求出  $A$  和  $k$

$$\text{函数式} \begin{cases} y = \frac{1}{1 + e^{-(w^T x + b)}} \\ \ln \frac{y}{1-y} = w^T x + b \\ \text{几率: } x \text{ 取1的相对几率为 } \frac{y}{1-y} \quad (x=1 \text{ 且 } p(x \text{ 为正值}) \text{ 的相对几率为 } y, x=0 \text{ 的几率为 } 1-y) \\ \text{对数几率: } \ln \frac{y}{1-y} \end{cases}$$

本质: 用线性回归模型的结果去逼近真实标记的对数几率

$$\text{反函数} \quad \left| \frac{k-p}{K} \right| = e^{-kt-C} \Leftrightarrow \left| \frac{k-p}{K} \right| = e^C e^{-kt} \Leftrightarrow \frac{k-p}{K} = \pm e^C e^{-kt} \Leftrightarrow \frac{k-p}{K} = A e^{-kt} \quad (A = \pm e^C)$$

$$\Leftrightarrow \frac{k}{K} - 1 = A e^{-kt} \Leftrightarrow \frac{k}{K} = 1 + A e^{-kt} \Leftrightarrow \frac{p}{K} = \frac{1}{1 + A e^{-kt}} \Rightarrow p = \frac{K}{1 + A e^{-kt}}$$

即p的通式为  $p(t) = \frac{K}{1 + A e^{-kt}}$  为了求出A, 令t=0  $p_0 = \frac{K}{1 + A e^0} \Rightarrow A = \frac{k-p_0}{p_0}$


对应目标函数,  $x=0$  时  $y=0.5$ , 即  $p(0)=0.5$ , 又因  $y' = y(1-y)$ , 即  $k=1$ , 可计算  $A=1$

至此得到  $y = \frac{1}{1 + e^{-x}}$ , sigmoid

## LDA线性判断分析

### 基本思想

给定训练样例集, 设法将样例投影到一条直线上, 使得同类样例的投影点尽可能接近、异类样例的投影点尽可能远离; 在对新样本进行分类时, 将其投影到同样的这条直线上, 再根据投影点来确定新样本的类别



LDA的二维示意图, "+"、"-" 分别代表正例和反例, 椭圆表示数据簇的外轮廓, 虚线表示投影

## 多分类学习—拆解法 拆分为若干个二分类

### 类别不平衡问题 处理方法 (以逻辑回归为例)

当正反例可能性相同 若  $\frac{y}{1-y} > 1$ , 则预测为正例

假设训练集是样本总体的无偏采样  
总体提供提升的代价, 采集过采样数据比例

再缩放  $\begin{cases} \text{若分类器默认基于正反可能性相同预测, 只需} \\ \text{需 } \frac{y}{1-y} = \frac{y}{1-y} \times \frac{m}{m'} \end{cases}$

当正例数量  $m+$ , 反例数量  $m-$  若  $\frac{y}{1-y} > \frac{m-}{m+}$ , 则预测为正例

若上面假设不成立, 则无法基于训练集类别数量推断真实几率

### 欠采样

删除一些样本, 使得正反例数目接近  
但也可能因此丢失一些重要信息

### 过采样

解决方法: EasyEnsemble算法——将反例划分为若干个集合供不同的学习器使用, 每个学习器都进行了欠采样, 全局来看却不会丢失重要信息

增加一些样本  
不能简单地对初始样本进行重复采样, 否则会招致严重的过拟合


### 阈值移动

“再缩放”也是“代价敏感学习”的基础, 在代价敏感学习中  $m-/m+$  用  $\text{cost-}/\text{cost+}$  代替即可, 其中  $\text{cost+}$  是将正例误分为反例的代价,  $\text{cost-}$  则是将反例误分为正例的代价

### 基本思想

已知样本集  $X$ , 预测函数  $f(x) = w^T x + b = \hat{y}$   
对预测值和真实值作差得到损失函数  $\text{loss} = |y - \hat{y}|$   
若把  $f(x)$  表示为矩阵形式 (表示为  $\theta$ ), 则有  $\text{loss} = |y - H\theta|$   
欲求  $\text{loss}$  的最小值, 即对  $h(\theta)$  求导  
若  $h(\theta) = 0$ ,  $\theta$  就是要找的极值

但对于高维空间求导比较困难, 可考虑以下方法  
任意给定  $\theta$  一个初始值, 解出该值下的  $\text{loss}$  和  $h(\theta)$   
若  $h(\theta) > 0$ , 说明函数此时在上升, 所以需要将  $\theta$  回退几个单位, 直到  $h(\theta)$  接近或等于 0  
如  $h(\theta) > 0$  时, 因退后的  $\theta' = \theta - h(\theta)$ ,  $\eta$  学习率, 可被  
回退后再次求的  $\text{loss}$  和  $h(\theta)$  并循环往复  
直到  $\text{loss}$  值小到我们可接受的范围或  $h(\theta)$  越接近 0



### 批量梯度下降

将上述问题扩展到多维时, 就需要对每一个方向都求偏导 (梯度)

$$\frac{\partial}{\partial \theta_j} \text{MSE}(\theta) = \frac{\partial}{\partial \theta_j} \left( \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2 \right) x_j^{(i)}$$

$$\text{损失函数对参数的偏导 } \nabla \theta \text{MSE}(\theta) = \begin{pmatrix} \frac{\partial}{\partial \theta_0} \text{MSE}(\theta) \\ \frac{\partial}{\partial \theta_1} \text{MSE}(\theta) \\ \vdots \\ \frac{\partial}{\partial \theta_n} \text{MSE}(\theta) \end{pmatrix} = \frac{1}{n} X^T (X\theta - y)$$

参数更新  $\theta^{(\text{next step})} = \theta - \eta \nabla_{\theta} \text{MSE}(\theta)$

要求所有的方向都求出偏导后, 才算走了一步, 所以处理速度较慢

### 随机梯度下降

每次随机随机选择一个方向, 每次迭代处理的数据很少, 处理速度高

达到最小值不会稳定下来, 会继续弹跳, 因此算法停止时, 最终的参数是一个比较好的参数, 但不是最佳的

### 学习率(Learning Rate)

参数更新时, 需要选择合适的学习率。若学习率太低, 处理数据速度会变慢; 如果太高, 容易掠过最低点


#### 寻找合适的学习率

网格搜索  $\begin{cases} \text{使用网格搜索, 设定迭代次数, 尝试几种可能的参数,} \\ \text{比较结果, 选择最优} \end{cases}$

梯度限制  $\begin{cases} \text{设置大量的迭代, 当梯度向量变小于一个值是} \\ \text{停止} \end{cases}$

### 局部最优和全局最优

有时候我们找到的点可能只是局部最优, 还需要添加其他参数辅助查找全局最优。但一般情况下, 只要该局部最优点的损失是在可控范围内就可以了



## 梯度下降